PREDIKSI KEMUNCULAN HOTSPOT SATU HARI KE DEPAN BERBASIS ZONA SPASIAL HDBSCAN DI KALIMANTAN TENGAH MENGGUNAKAN RANDOM FOREST, XGBOOST, DAN SOFT VOTING

Kelompok Weather

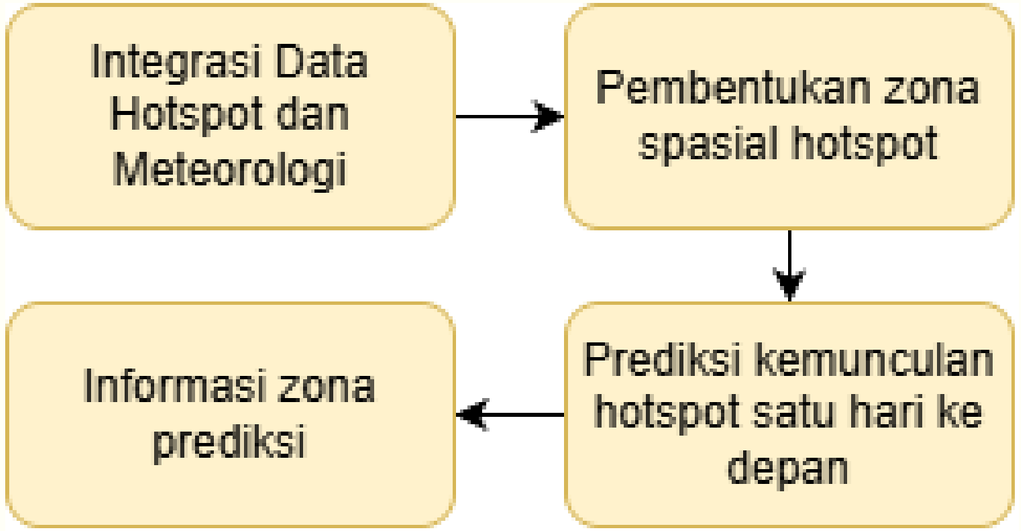
Latar Belakang

- Kebakaran hutan dan lahan menjadi isu penting di Kalimantan
- 6.184 hotspot di lahan gambut dan 4.848 di lahan non-gambut selama 2019–2023
- Kalimantan Tengah mencatat 7.526 titik panas (hotspot), tertinggi di Indonesia per 22 Oktober 2026.
- Kemunculan hotspot dipengaruhi oleh kondisi meteorologi dan pola temporal
- Random Forest dan XGBoost telah digunakan untuk memodelkan kerentanan kebakaran di Indonesia
- Prediksi hotspot H+1 per zona di Kalimantan Tengah menggunakan HDBSCAN, Random Forest, XGBoost, dan Soft Voting

Tujuan

Membentuk zona spasial menggunakan HDBSCAN serta membandingkan Random Forest, XGBoost, dan Soft Voting untuk memprediksi kemunculan hotspot satu hari ke depan.

Solusi



Kebermanfaatan

Mendukung penentuan prioritas pemantauan zona yang diprediksi mengalami hotspot, perbandingan kinerja model berdasarkan evaluasi terukur, serta pengembangan sistem pendukung keputusan untuk pemantauan dan kesiapsiagaan karhutla.

Sumber Data dan Karakteristik

Sumber: NASA FIRMS · NASA POWER Daily API

Data Hotspot

Sumber Data: NASA FIRMS
Jumlah Baris: 178.732 baris data awal
Satelit: VIIRS Suomi-NPP (SNPP)
Variabel utama: latitude, longitude, tanggal, confidence, brightness, dan FRP

Data Meteorologi

Sumber Data: NASA POWER
Jumlah Baris: 10.555 baris data harian
Lokasi: 5 lokasi Pengamatan
Variabel: T2M: suhu udara (°C), RH2M: kelembapan relatif (%), PRECTOTCORR: curah hujan (mm/hari), dan WS10M: kecepatan angin pada ketinggian 10 m (m/s).

Periode data: 1 Januari 2021 – 12 Oktober 2026

Data Wrangling, Preprocessing, dan Feature Engineering

Data Hotspot

1. Mengubah format tanggal dan memilih kolom yang diperlukan.
2. Menghapus deteksi ber-confidence rendah (l).
3. Mempertahankan confidence nominal (n) dan tinggi (h).
4. Menyeleksi titik berdasarkan batas administratif Kalimantan Tengah.

Data Awal: 178.732 baris

Data Setelah Preprocessing: 172.129 baris

Data Meteorologi

1. Mengubah kolom tanggal menjadi format tanggal.
2. Menghapus duplikasi lokasi dan tanggal.
3. Mengubah nilai -999 menjadi missing value.
4. Mengisi missing value dengan interpolasi per stasiun.

Hasil penanganan missing value: 0

Pembentukan Fitur Meteorologi

1. Akumulasi curah hujan selama 3, 7, 14, 30, dan 60 hari.
2. Rata-rata suhu dan kelembapan selama 7 hari.
3. Hari kering berturut-turut.
4. Vapor Pressure Deficit (VPD) dan rata-rata VPD 7 hari.

Pembentukan Zona Spasial Menggunakan HDBSCAN

Tujuan

Mengelompokkan titik hotspot berdasarkan kedekatan geografis agar prediksi dapat dilakukan pada tingkat zona spasial.

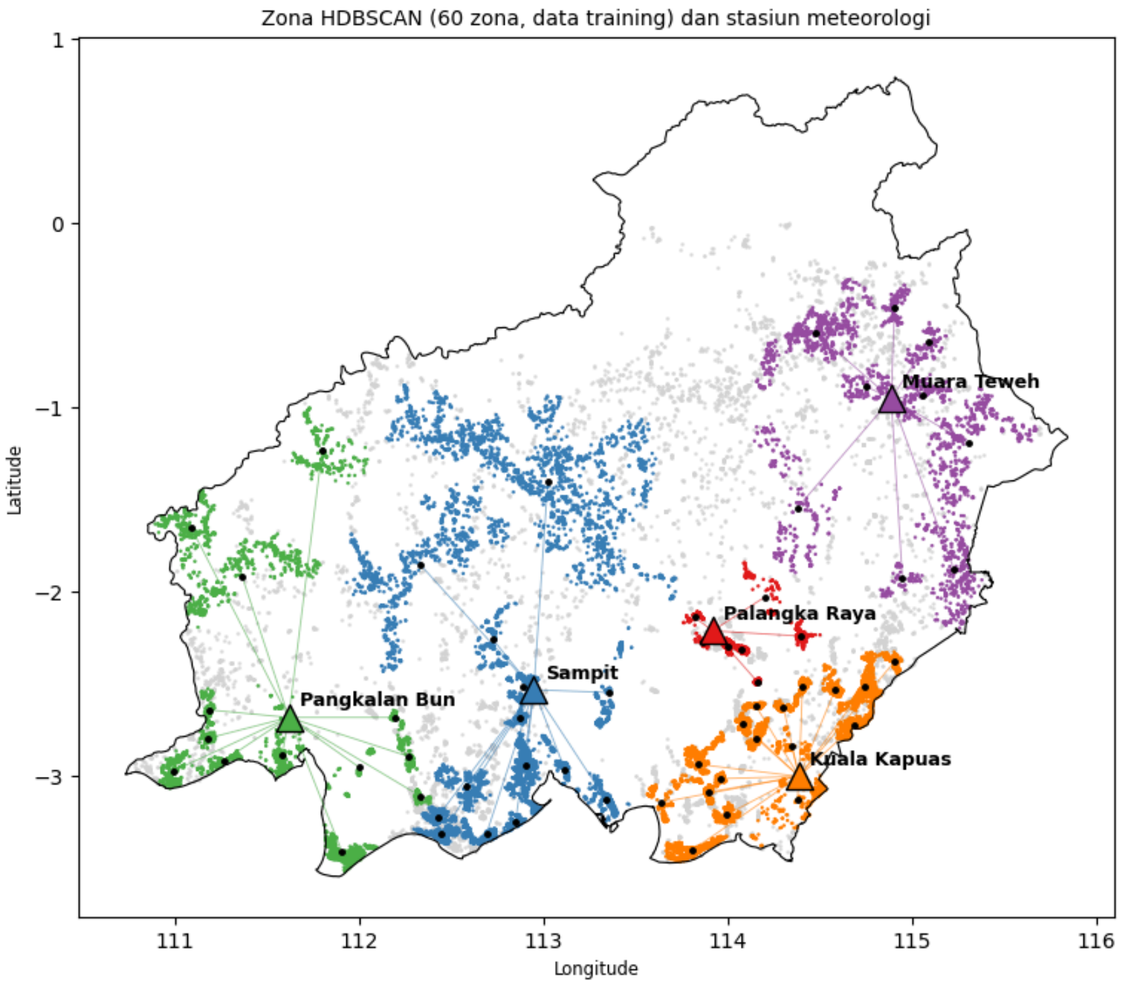
Parameter HDBSCAN

- min_cluster_size = 150
- min_samples = 30
- Metrik jarak = Haversine
- Metode pemilihan cluster = EOM
- Data pembentukan zona: hotspot hingga 31 Desember 2024.

Hasil Pembentukan Zona

60
Zona spasial terbentuk

67%
Hotspot data uji berhasil ditugaskan ke zona



Target Prediksi, Fitur, dan Pembagian Data Temporal

- Target (H+1): untuk setiap zona HDBSCAN, 1 jika ada deteksi hotspot pada hari berikutnya, 0 jika tidak
- Unit data: zona × hari (satu baris = satu zona pada satu tanggal)
- 31 fitur dalam 5 kelompok: meteorologi (15), riwayat hotspot zona (7), spasial statis (3), tetangga dan provinsi (4), musim (2)
- Pembagian temporal:
  - Latih: 2021 sampai 2024
  - Validasi silang per tahun: latih ≤2022 → validasi 2023; latih ≤2023 → validasi 2024
  - Uji: 2025 sampai 12 Oktober 2026

Contoh dengan target = 1:

zona	tanggal	T2M	RH2M	PRECTOTCORR	CH_7d	HKB	hs_hari_ini	hs_7d	target
2	2023-09-15	27.88	74.56	0.75	2.09	6.97	1.0	4.0	1
15	2023-09-15	27.93	74.52	0.53	2.14	6.65	1.0	7.0	1
31	2023-09-15	28.43	71.83	0.18	1.25	6.70	0.0	6.0	1
35	2023-09-15	27.62	77.06	0.14	2.46	4.67	1.0	7.0	1
39	2023-09-15	27.56	77.61	0.13	2.21	4.89	1.0	7.0	1

Contoh dengan target = 0:

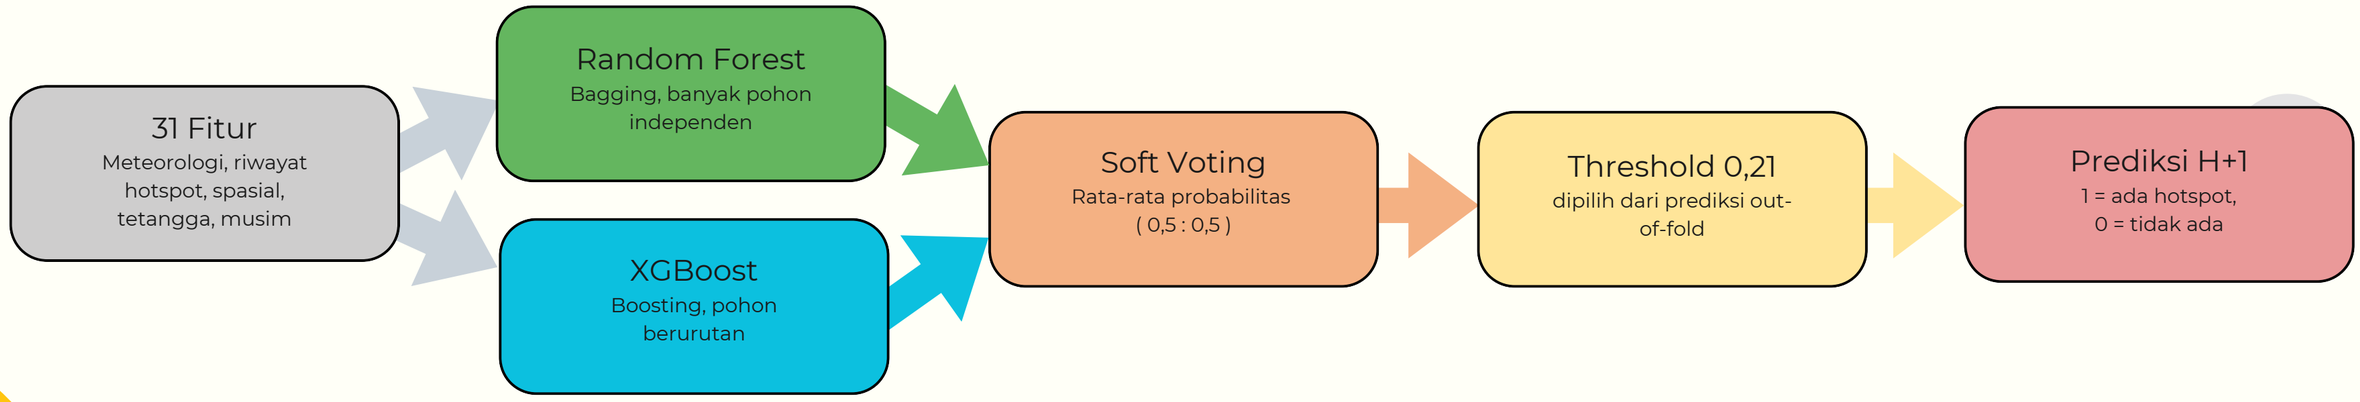
zona	tanggal	T2M	RH2M	PRECTOTCORR	CH_7d	HKB	hs_hari_ini	hs_7d	target
0	2023-09-15	27.94	74.33	0.62	2.04	6.83	1.0	5.0	0
1	2023-09-15	27.84	75.11	0.50	2.55	6.53	0.0	3.0	0
3	2023-09-15	27.87	74.79	0.57	2.32	6.69	0.0	2.0	0
4	2023-09-15	28.17	73.72	0.15	1.29	6.59	0.0	4.0	0
5	2023-09-15	27.87	74.71	0.64	2.22	6.79	1.0	7.0	0

Penanganan Imbalance Data

- Kelas hotspot adalah minoritas: positif hanya 4,9% (latih), 3,0% (uji 2025), 21,0% (uji 2026)
- Metrik utama adalah PR-AUC, precision, recall, F1
- Tiga skenario dibandingkan lewat validasi silang per tahun:
  - Tanpa penanganan (pembanding)
  - Class weight: kelas hotspot diberi bobot lebih besar
  - Undersampling ensemble: 10 model, masing-masing dilatih pada subset negatif acak 1:1, probabilitas dirata-ratakan
- Resampling hanya pada data latih tiap lipatan. Validasi dan uji tetap data asli
- Threshold dituning dari prediksi out-of-fold sebagai penanganan di level keputusan

Arsitektur Ensemble dan Tuning

- Dua model dasar dilatih paralel pada 31 fitur yang sama
- Soft voting: probabilitas hotspot dari kedua model dirata-ratakan (bobot 0,5 : 0,5), lalu dibandingkan dengan threshold (0,21, dari prediksi out-of-fold) → prediksi 0/1
- Tuning: RandomizedSearchCV, 15 kombinasi, 2 lipatan temporal, skor PR-AUC
- Tangga pembanding: Persistence → baseline default → model tuned → Soft Voting

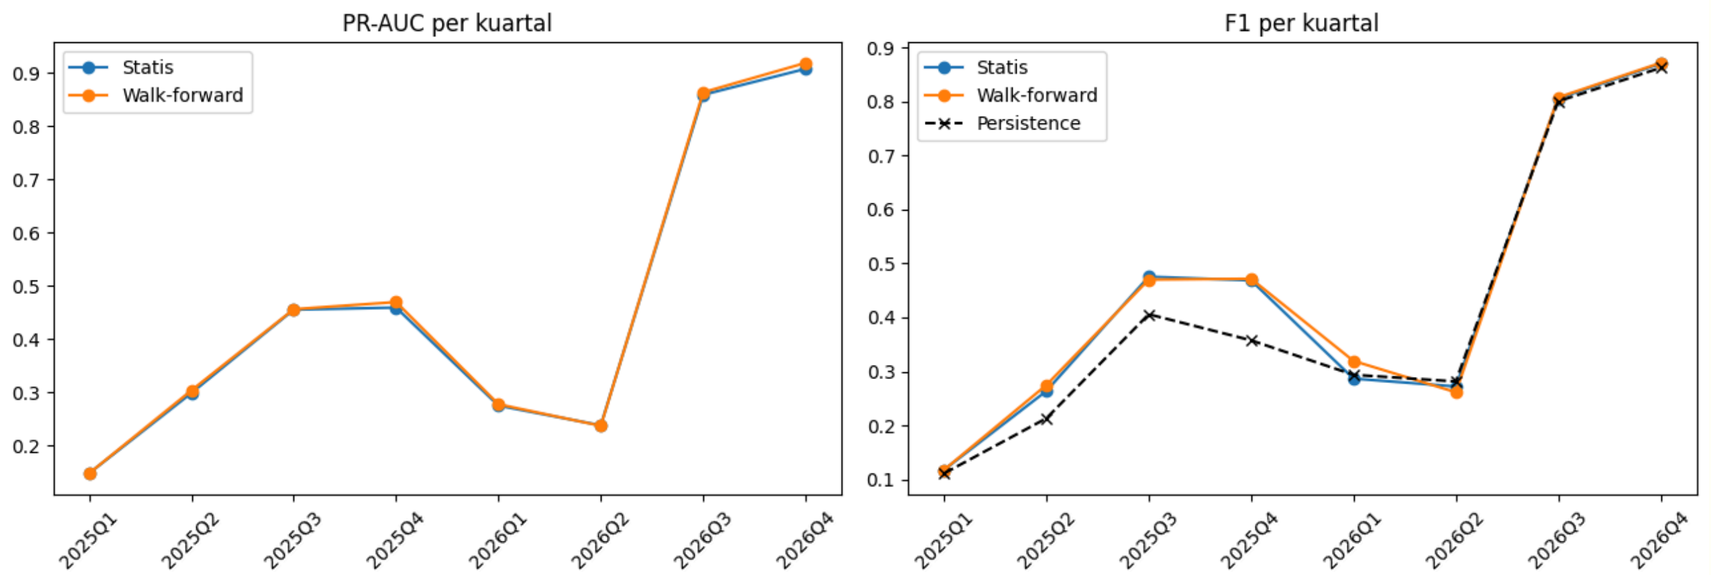


Perbandingan Hasil Seluruh Model

Model	Precision	Recall	F1-score	PR-AUC
Random Forest	0,6827	0,8128	**0,7421**	0,7897
XGBoost	0,6311	**0,8501**	0,7244	**0,8011**
Soft Voting	0,6693	0,8283	0,7404	0,7984
Persistence	0,7062	0,6994	0,7028	0,5266

Berdasarkan hasil evaluasi, Random Forest memperoleh F1-Score tertinggi sebesar 0,7421, menunjukkan keseimbangan terbaik antara ketepatan dan kemampuan mendeteksi hotspot. XGBoost memiliki Recall tertinggi sebesar 0,8501 dan PR-AUC tertinggi sebesar 0,8011. Soft Voting memberikan hasil baik, tetapi belum mengungguli kedua model pada metrik terbaiknya. Dengan demikian, Random Forest lebih seimbang, sedangkan XGBoost lebih unggul dalam mendeteksi hotspot.

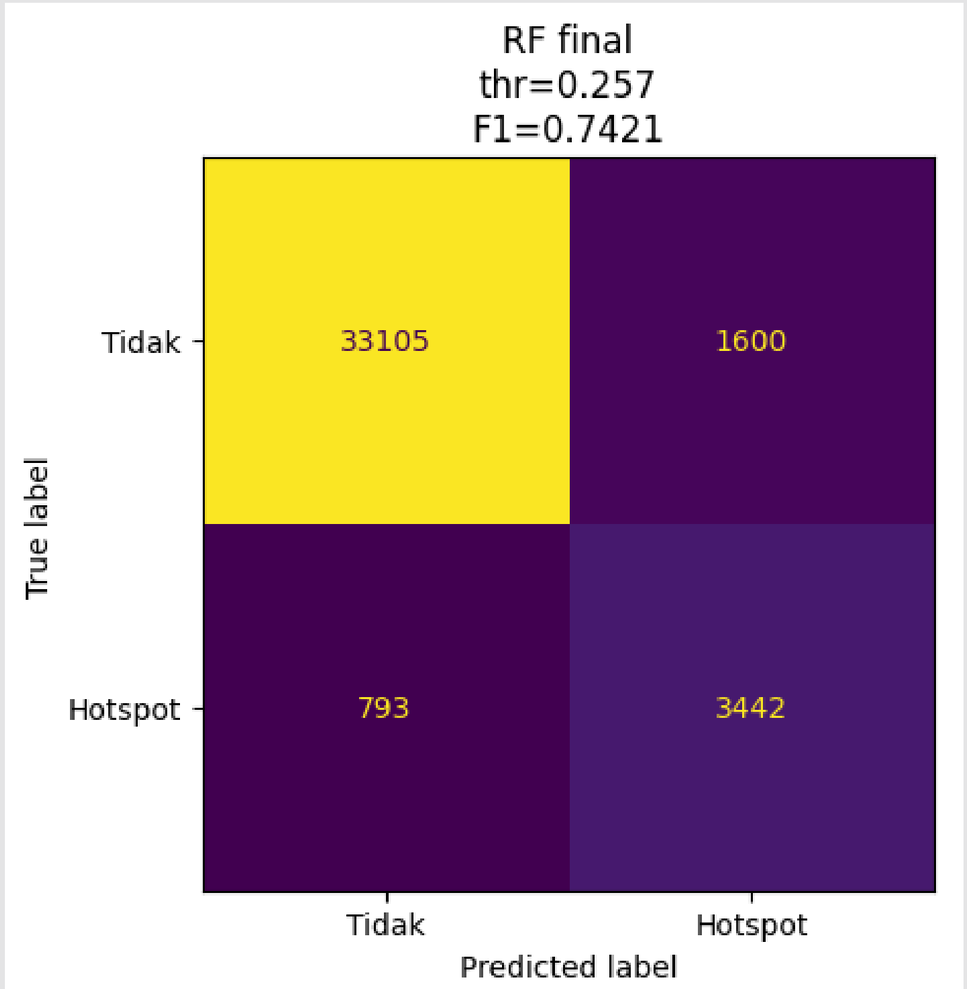
Stabilitas Performa dan Walk-Forward Retraining



Performa model statis dan walk-forward menunjukkan pola PR-AUC dan F1-score yang relatif sama, dengan peningkatan tajam pada kuartal ketiga dan keempat tahun 2026. Walk-forward hanya memberikan peningkatan kecil pada beberapa kuartal dan belum menunjukkan keunggulan yang konsisten. Dibandingkan baseline Persistence, F1-score model lebih tinggi pada beberapa kuartal, terutama pada 2025 Q2–Q4 dan 2026 Q1.

Analisis Kesalahan dan Keterbatasan

Confusion matrix menunjukkan bahwa Random Forest berhasil memprediksi 33.105 data bukan hotspot dan 3.442 data hotspot dengan benar. Namun, terdapat 1.600 prediksi hotspot yang keliru dan 793 hotspot yang tidak terdeteksi. Secara keseluruhan, model cukup baik dalam mendeteksi hotspot dengan nilai F1-score sebesar 0,7421, tetapi masih terdapat kesalahan prediksi yang perlu diperhatikan.



Conclusion

- Dari hasil pengujian, Random Forest memberikan hasil terbaik berdasarkan F1-score sebesar 0,7421. Meski begitu, XGBoost juga unggul dalam mendeteksi hotspot dan nilai PR-AUC. Jadi, setiap model punya kelebihan masing-masing dalam memprediksi kemunculan hotspot sehari ke depan.
- Ke depannya, pengembangan selanjutnya dapat menggunakan data yang lebih lengkap, memperbaiki prediksi di wilayah yang belum tercakup zona, dan melakukan pembaruan model secara berkala agar hasil prediksinya semakin baik.





Thank You